

UNIVERSIDAD NACIONAL DE COLOMBIA

Facultad de Ingeniería y Arquitectura

**Análisis de datos mediante técnicas de
Machine Learning**

MONOGRAFÍA

Para optar al título de: Ingeniero Electrónico

Autor:

Jholman Dasney Meza Pasinga

Tutor:

Jorge Hernan Estrada Estrada

Manizales, Colombia

2026

Índice general

Resumen	1
1. Introducción	2
1.1. Contexto histórico y tecnológico	2
1.2. Planteamiento del problema	2
1.3. Objetivos	3
1.4. Alcance y limitaciones	3
2. Datos para Machine Learning	5
2.1. ¿Qué son los datos?	5
2.2. Tipos de datos	5
2.2.1. Datos estructurados	5
2.2.2. Datos semiestructurados	5
2.2.3. Datos no estructurados	5
2.3. Variables, características y etiquetas	6
2.4. Exploración inicial de los datos	6
2.5. Limpieza de datos	6
2.6. Transformación y preparación de datos	6
2.6.1. Normalización	7
2.6.2. Estandarización	7
2.7. División de datos: entrenamiento, validación y prueba	7
3. Fundamentos del aprendizaje automático	9
3.1. Concepto de Machine Learning	9
3.2. Modelos de aprendizaje supervisado	10
3.2.1. Regresión lineal	10
3.2.2. Regresión logística	11
3.2.3. Árboles de decisión	12
3.2.4. Random Forest	12
3.2.5. K-Nearest Neighbors (KNN)	13
3.2.6. Redes neuronales artificiales	13
3.3. Aprendizaje no supervisado y sus modelos	14

3.3.1.	Conglomerados o clustering	14
3.3.2.	K-Means	15
3.3.3.	Análisis de Componentes Principales (PCA)	15
4.	Aplicación computacional de modelos supervisados	17
4.1.	Predicción del valor medio de viviendas en California mediante regresión lineal	17
4.1.1.	Objetivo de la aplicación	17
4.1.2.	Descripción de la base de datos	17
4.1.3.	Implementación del código en Python	18
4.1.4.	Análisis y resultados	18
4.1.4.1.	Gráfica regresión lineal	18
4.1.4.2.	Gráfico de diagnóstico de predicción	19
4.1.4.3.	Métricas de evaluación	19
4.1.5.	Conclusión y reflexión	20
4.2.	Clasificación de tumores benignos y malignos mediante regresión logística . .	20
4.2.1.	Objetivo	20
4.2.2.	Descripción base de datos	20
4.2.3.	Implementación del Código en Python	21
4.2.4.	Análisis y resultados	21
4.2.4.1.	Distribución de clases	21
4.2.4.2.	Matriz correlación	22
4.2.4.3.	Matriz de confusión	23
4.2.4.4.	Métricas de evaluación	23
4.2.5.	Conclusiones	24
5.	Aplicación computacional de modelos no supervisados	25
5.1.	Agrupamiento de flores Iris mediante K-Means	25
5.1.1.	Objetivo	25
5.1.2.	Descripción de la base de datos	25
5.1.3.	Implementación del Código en Python	25
5.1.4.	Análisis y resultados	26
5.1.4.1.	Distribución real	26
5.1.4.2.	Optimización mediante el método del codo	27
5.1.4.3.	Clústeres encontrados por k-means	27
5.1.4.4.	Métricas generales	28
5.1.5.	Conclusión	29
5.2.	Análisis de Componentes Principales (PCA)	29

5.2.1. Objetivo de la aplicación	29
5.2.2. Descripción de la base de datos	29
5.2.3. Código Python	29
5.2.4. Análisis de resultados	30
5.2.4.1. Distribución de clases	30
5.2.4.2. Varianza explicada y acumulada	30
5.2.4.3. Proyección de los datos con PCA	31
5.2.4.4. Contribución de variables	32
5.2.5. Conclusión	33
6. Análisis crítico, retos y tendencias futuras	34
6.1. Calidad de los datos	34
6.2. Privacidad y seguridad de la información	35
6.3. Costos computacionales	35
7. Conclusiones y recomendaciones	36
7.1. Conclusiones generales	36
7.2. Recomendaciones para el uso adecuado del aprendizaje automático	36

Resumen

La presente monografía aborda el análisis de datos mediante técnicas de aprendizaje automático, destacando la importancia de la preparación, calidad y correcta interpretación de la información antes de aplicar modelos computacionales. El trabajo parte del estudio de los datos como materia prima de los sistemas inteligentes,

Asimismo, se presentan los fundamentos del Machine Learning (ML), diferenciando entre aprendizaje supervisado y no supervisado. En el aprendizaje supervisado se analizan modelos de regresión y clasificación. En el aprendizaje no supervisado se estudian técnicas como K-Means (*Agrupación en clústeres*) y PCA (*Análisis de componentes principales*), orientadas al descubrimiento de agrupamientos, reducción de dimensionalidad y visualización de estructuras internas en los datos.

En el contexto actual, los modelos de Inteligencia Artificial y Machine Learning no deben ser interpretados como entidades infalibles que reemplazan el criterio humano, sino como herramientas analíticas de alta fidelidad que actúan como catalizadores. Su verdadero valor radica en la capacidad de procesar grandes volúmenes de información dispersa, mitigar la incertidumbre y visibilizar patrones ocultos a simple vista.

Capítulo 1

Introducción

1.1. Contexto histórico y tecnológico

Históricamente, el análisis de datos estuvo asociado principalmente al uso de métodos estadísticos, hojas de cálculo y bases de datos tradicionales. Durante mucho tiempo, las organizaciones utilizaron la información para elaborar reportes, calcular indicadores y describir situaciones ocurridas en el pasado. Sin embargo, con el avance de la computación, el crecimiento de internet, la digitalización de procesos y el aumento en la capacidad de almacenamiento, los datos comenzaron a ocupar un lugar central en el desarrollo de nuevas tecnologías.

El surgimiento de la inteligencia artificial y del aprendizaje automático permitió cambiar la forma de utilizar los datos. En lugar de limitarse únicamente a describir información, los sistemas comenzaron a aprender patrones y relaciones para realizar predicciones o apoyar decisiones. Arthur Samuel fue uno de los primeros autores en utilizar el término *Machine Learning*, al referirse a la capacidad de los computadores para aprender sin ser programados explícitamente para cada tarea (Samuel, 1959). Posteriormente, Mitchell (1997) planteó que un programa aprende de la experiencia cuando mejora su desempeño en una tarea determinada a partir de dicha experiencia.

Con el paso del tiempo, el desarrollo de algoritmos más avanzados, el aumento de la capacidad computacional y la disponibilidad de mayores cantidades de datos impulsaron el crecimiento del Machine Learning (Alpaydin, 2020). Gracias a esta evolución, modelos fundamentales empezaron a utilizarse de manera masiva en problemas de clasificación, predicción, segmentación y detección de patrones.

1.2. Planteamiento del problema

En el entorno organizacional contemporáneo, la acumulación masiva de datos no se traduce automáticamente en la generación de valor estratégico. El problema central radica en la brecha analítica entre la posesión de datos crudos y su transformación para convertirse en

información útil. Tradicionalmente, la interpretación de la información se ha limitado a la estadística descriptiva convencional, un enfoque reactivo que solo explica eventos pasados y carece de la flexibilidad matemática para identificar correlaciones complejas y no lineales en variables multivariadas.

Fundamentar la toma de decisiones en análisis estáticos o en la intuición humana eleva drásticamente el riesgo operativo y la incertidumbre. Ante la incapacidad de anticipar comportamientos futuros con un margen de error controlable, las organizaciones subestiman los riesgos del entorno y ejecutan planificaciones subóptimas. Para abordar esta problemática, el Aprendizaje Automático (*Machine Learning*) surge como el paradigma metodológico idóneo. Sin embargo, el desafío técnico no se limita a la mera ejecución algorítmica, sino que exige una evaluación rigurosa de sus métricas de rendimiento y la validación estadística de sus supuestos subyacentes; solo mediante este control es posible garantizar la robustez, capacidad de generalización y confiabilidad de las predicciones como soporte en la toma de decisiones críticas.

A partir de este escenario de incertidumbre metodológica y analítica, se formula la siguiente pregunta de investigación: **¿Cómo contribuyen las técnicas de Machine Learning al análisis de datos para identificar patrones, generar predicciones y apoyar la toma de decisiones?**

1.3. Objetivos

- Evaluar la contribución de las técnicas de *Machine Learning* supervisado en el análisis de datos mediante el desarrollo de modelos supervisados y no supervisados.
- Analizar la importancia de los datos, su preparación y su calidad en el desarrollo de modelos de *Machine Learning* identificando los procesos fundamentales que permiten transformar la información en conocimiento útil para la toma de decisiones.

1.4. Alcance y limitaciones

La presente monografía se enfoca en el estudio teórico y descriptivo de los datos como base para el desarrollo de modelos de *Machine Learning*. Y en la aplicación de estos modelos de manera computacional. El trabajo aborda conceptos fundamentales relacionados con los datos, la información, y la inteligencia artificial.

El alcance del trabajo comprende la explicación conceptual de las etapas que conforman el flujo de trabajo de un proyecto de aprendizaje automático, desde la obtención de los

datos hasta su uso en modelos predictivos o clasificatorios. También se consideran aspectos importantes como la calidad, representatividad, sesgo, privacidad e interpretación de los resultados.

Sin embargo, esta monografía no tiene como propósito desarrollar un nuevo algoritmo de *Machine Learning*. Tampoco se pretende construir una plataforma tecnológica completa ni entrenar modelos avanzados con grandes bases de datos reales. Los ejemplos de programación que se incluyan tendrán un propósito explicativo y académico, orientado a mostrar de manera sencilla cómo se aplican algunos conceptos.

De igual manera, el trabajo no profundiza en el desarrollo matemático avanzado de todos los modelos existentes, sino que presenta las bases necesarias para comprender su funcionamiento general. El enfoque principal será conceptual, analítico y aplicado, con énfasis en la importancia de los datos dentro del proceso de aprendizaje automático.

Capítulo 2

Datos para Machine Learning

2.1. ¿Qué son los datos?

Los datos pueden definirse como representaciones de hechos, mediciones, observaciones o características asociadas a un fenómeno determinado. En el contexto del *Machine Learning*, los datos son utilizados para construir modelos capaces de identificar patrones, aprender relaciones entre variables y realizar predicciones sobre nuevos casos. Cada registro de una base de datos puede representar una observación del fenómeno que se desea estudiar. Desde una perspectiva computacional, los datos suelen organizarse en matrices, tablas o estructuras multidimensionales.

2.2. Tipos de datos

Los datos pueden clasificarse de diferentes maneras según su estructura, naturaleza y forma de representación.

2.2.1. Datos estructurados

Los datos estructurados son aquellos que se encuentran organizados en tablas con filas y columnas. Cada columna representa una variable y cada fila corresponde a una observación.

2.2.2. Datos semiestructurados

Los datos semiestructurados no se organizan estrictamente en tablas, pero poseen cierta estructura interna. Algunos ejemplos son archivos JSON, XML, registros de servidores, correos electrónicos y documentos con etiquetas.

2.2.3. Datos no estructurados

Los datos no estructurados son aquellos que no siguen una estructura fija. Entre ellos se encuentran imágenes, audios, videos, textos libres, publicaciones en redes sociales y docu-

mentos digitales.

2.3. Variables, características y etiquetas

los datos se componen principalmente de características y etiquetas. Las características, también llamadas variables de entrada o *features*, son los atributos que describen cada observación. La etiqueta, también llamada variable objetivo o *target*, es el resultado que se desea predecir.

2.4. Exploración inicial de los datos

Antes de construir un modelo, es necesario realizar una exploración inicial de los datos. Esta etapa permite comprender la estructura de la información, identificar el tipo de variables, revisar valores faltantes, detectar posibles errores y observar comportamientos generales.

El análisis exploratorio de datos, conocido como EDA por sus siglas en inglés (*Exploratory Data Analysis*), incluye herramientas estadísticas y gráficas. Entre las técnicas más comunes se encuentran el cálculo de medidas de tendencia central, dispersión, distribución de variables, correlaciones, histogramas, diagramas de caja y gráficos de dispersión.

Esta etapa es importante porque permite conocer el estado real de los datos antes del modelado. Además, ayuda a tomar decisiones sobre limpieza, transformación, selección de variables y tratamiento de valores atípicos.

2.5. Limpieza de datos

La limpieza de datos es una de las etapas más importantes en cualquier proyecto de *Machine Learning*. Consiste en identificar y corregir problemas presentes en los datos, tales como valores faltantes, duplicados, errores de escritura, inconsistencias, datos fuera de rango o registros incorrectos. La calidad de los datos influye directamente en la calidad del modelo. Por esta razón, una mala limpieza puede producir modelos poco precisos, conclusiones equivocadas o decisiones incorrectas.

2.6. Transformación y preparación de datos

Después de limpiar los datos, es necesario transformarlos para que puedan ser utilizados adecuadamente por los algoritmos. Muchos modelos de aprendizaje automático requieren que los datos estén en formato numérico, escalado y organizado.

2.6.1. Normalización

Una transformación común es la normalización, que permite ajustar los valores de una variable a un rango determinado, generalmente entre 0 y 1. Esta técnica es útil cuando las variables tienen escalas muy diferentes.

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (2.1)$$

2.6.2. Estandarización

Otra técnica frecuente es la estandarización, que transforma los datos para que tengan media cero y desviación estándar igual a uno.

$$z = \frac{x - \mu}{\sigma} \quad (2.2)$$

Donde (x) representa el valor original, (μ) la media de la variable y (σ) su desviación estándar. También es común codificar variables categóricas. Por ejemplo, una variable como “color” con categorías rojo, azul y verde debe convertirse en una representación numérica para que el modelo pueda procesarla. Esto puede realizarse mediante técnicas como codificación ordinal o *one-hot encoding*.

2.7. División de datos: entrenamiento, validación y prueba




Figura 2.1: Valores reales vs Valores predichos

El conjunto de entrenamiento se utiliza para ajustar el modelo. A partir de estos datos, el algoritmo aprende los patrones y relaciones presentes en la información.

El conjunto de validación se utiliza para ajustar parámetros del modelo y comparar diferentes configuraciones. Este conjunto permite evaluar el desempeño durante el proceso de desarrollo sin utilizar aún los datos finales de prueba.

El conjunto de prueba se utiliza al final para medir el rendimiento del modelo con datos que no fueron usados durante el entrenamiento. Esto permite estimar qué tan bien puede generalizar el modelo ante datos nuevos.

Capítulo 3

Fundamentos del aprendizaje automático

3.1. Concepto de Machine Learning

El *Machine Learning* puede definirse como una rama de la inteligencia artificial orientada al desarrollo de algoritmos capaces de aprender a partir de datos. Arthur Samuel fue uno de los primeros autores en utilizar el término *Machine Learning*, al describirlo como el campo que permite a los computadores aprender sin ser programados explícitamente para cada tarea (Samuel, 1959).

En términos generales, el aprendizaje automático trabaja con datos de entrada que describen un fenómeno. Estos datos pueden estar representados en forma de tablas, imágenes, textos, audios, videos o señales. A partir de esta información, el modelo intenta encontrar relaciones entre las variables disponibles y el resultado esperado, o bien descubrir estructuras internas cuando no existe una respuesta previamente definida.

Matemáticamente, un modelo de aprendizaje automático puede entenderse como una función que recibe datos de entrada y genera una salida. Esta función puede representarse de la siguiente manera:

$$\hat{y} = f(x) \tag{3.1}$$

Donde (x) representa los datos de entrada, $f(x)$ representa el modelo aprendido y $(\hat{y})$ corresponde a la predicción realizada por el modelo. Durante el entrenamiento, el objetivo es ajustar los parámetros internos del modelo para que la predicción $(\hat{y})$ sea lo más cercana posible al valor real (y) .

Para medir qué tan buena es la predicción, se utiliza una función de pérdida o función de error. Esta función compara el valor real con el valor predicho y permite cuantificar el error cometido por el modelo. De manera general, el proceso de entrenamiento busca minimizar dicho error:

$$\min_{\theta} \frac{1}{n} \sum_{i=1}^n L(y_i, f_{\theta}(x_i)) \quad (3.2)$$

En esta expresión, θ representa los parámetros del modelo, n es el número de observaciones, (y_i) es el valor real, $(f_{\theta}(x_i))$ es la predicción del modelo y (L) es la función de pérdida.

3.2. Modelos de aprendizaje supervisado

El aprendizaje supervisado es uno de los enfoques principales del *Machine Learning*. Se caracteriza porque el modelo se entrena utilizando un conjunto de datos que contiene variables de entrada y una salida conocida, llamada etiqueta o variable objetivo. El propósito es que el modelo aprenda la relación entre las características de entrada y la salida esperada, para luego realizar predicciones sobre datos nuevos.

En términos generales, un conjunto de datos supervisado puede representarse como:

$$D = (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n) \quad (3.3)$$

Donde (x_i) representa las características de entrada de la observación (i) , y (y_i) representa la salida real asociada. El objetivo del aprendizaje supervisado es encontrar una función $f(x)$ que permita aproximar la relación entre las entradas y las salidas:

$$\hat{y} = f(x) \quad (3.4)$$

En esta expresión, $(\hat{y})$ corresponde a la predicción realizada por el modelo. Durante el entrenamiento, el algoritmo ajusta sus parámetros para reducir la diferencia entre el valor real (y) y el valor predicho $(\hat{y})$. Esta diferencia se mide mediante una función de pérdida o error.

El aprendizaje supervisado se utiliza principalmente en dos tipos de problemas: regresión y clasificación. En los problemas de regresión, la variable objetivo es numérica, como el precio de una vivienda, la temperatura o la demanda de energía. En los problemas de clasificación, la variable objetivo pertenece a una categoría, como correo spam o no spam, paciente enfermo o sano, cliente aprobado o rechazado.

3.2.1. Regresión lineal

Su objetivo es predecir una variable numérica continua a partir de una o varias variables de entrada. El modelo supone que existe una relación lineal entre las variables independientes y la variable dependiente.

La forma general de una regresión lineal simple es:

$$\hat{y} = wx + b \quad (3.5)$$

Donde (x) es la variable de entrada, (w) es el peso o coeficiente del modelo, (b) es el sesgo o intercepto, y $(\hat{y})$ es la predicción.

Cuando existen varias variables de entrada, el modelo se expresa como:

$$\hat{y} = w_1x_1 + w_2x_2 + \cdots + w_mx_m + b \quad (3.6)$$

El objetivo del entrenamiento es encontrar los valores de los pesos que minimicen el error entre las predicciones y los valores reales. Una función de pérdida común en regresión lineal es el error cuadrático medio:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (3.7)$$

Este modelo es útil cuando se busca explicar o predecir una variable continua.

3.2.2. Regresión logística

La regresión logística es un modelo utilizado principalmente para problemas de clasificación binaria, es decir, cuando la salida puede pertenecer a una de dos clases posibles. Aunque su nombre incluye la palabra regresión, su propósito principal es clasificar.

El modelo calcula una combinación lineal de las variables de entrada y luego aplica la función sigmoide para obtener una probabilidad entre 0 y 1:

$$\hat{y} = \sigma(w_1x_1 + w_2x_2 + \cdots + w_mx_m + b) \quad (3.8)$$

La función sigmoide se define como:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (3.9)$$

Donde $(\mathbf{z})$ representa la combinación lineal de las variables. Si la probabilidad obtenida es mayor que un umbral, por ejemplo **0.5**, el modelo asigna la observación a una clase; si es menor, la asigna a la otra. La regresión logística se utiliza en problemas como detección de fraude, diagnóstico médico, clasificación de correos electrónicos y predicción de abandono de clientes.

3.2.3. Árboles de decisión

Los árboles de decisión son modelos supervisados que toman decisiones mediante una estructura jerárquica similar a un árbol. Cada nodo representa una pregunta o condición sobre una variable, cada rama representa una posible respuesta y cada hoja representa una predicción final.

En clasificación, el árbol busca dividir los datos de manera que las clases queden lo más separadas posible. Para medir la calidad de una división, se utilizan criterios como la impureza de Gini o la entropía.

La impureza de Gini se define como:

$$Gini = 1 - \sum_{k=1}^K p_k^2 \quad (3.10)$$

Donde (p_k) representa la proporción de elementos pertenecientes a la clase (k). Un valor bajo de Gini indica que el nodo contiene observaciones mayoritariamente de una sola clase.

La entropía se define como:

$$H = - \sum_{k=1}^K p_k \log_2(p_k) \quad (3.11)$$

La entropía mide el grado de desorden o incertidumbre en los datos. El árbol selecciona las divisiones que reduzcan la impureza o la incertidumbre.

Los árboles de decisión son fáciles de interpretar y pueden aplicarse tanto a problemas de clasificación como de regresión. Sin embargo, pueden presentar sobreajuste si crecen demasiado y se adaptan excesivamente a los datos de entrenamiento.

3.2.4. Random Forest

El bosque aleatorio, o *Random Forest*, es un modelo que combina varios árboles de decisión para mejorar la precisión y reducir el sobreajuste. En lugar de utilizar un solo árbol, el modelo entrena muchos árboles con diferentes subconjuntos de datos y variables.

En problemas de clasificación, la predicción final se obtiene mediante votación mayoritaria:

$$\hat{y} = \text{moda}(h_1(x), h_2(x), \dots, h_T(x)) \quad (3.12)$$

Donde ($h_T(x)$) representa la predicción del árbol (T).

En problemas de regresión, la predicción se obtiene promediando las salidas de todos los árboles:

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T h_t(x) \quad (3.13)$$

Los bosques aleatorios suelen ser más robustos que los árboles individuales, ya que reducen la dependencia de una única estructura de decisión. Son ampliamente utilizados en clasificación, predicción de riesgos, análisis financiero, diagnóstico médico y detección de anomalías.

3.2.5. K-Nearest Neighbors (KNN)

El algoritmo K vecinos más cercanos, o KNN, es un método supervisado basado en la similitud entre observaciones. Para clasificar un nuevo dato, el algoritmo busca los (K) puntos más cercanos dentro del conjunto de entrenamiento y asigna la clase más frecuente entre ellos.

La distancia más utilizada es la distancia euclidiana:

$$d(x_i, x_j) = \sqrt{\sum_{r=1}^m (x_{ir} - x_{jr})^2} \quad (3.14)$$

Donde (x_i) y (x_j) son dos observaciones, y (m) es el número de variables.

En clasificación, la predicción se obtiene mediante votación de los vecinos más cercanos. En regresión, se puede calcular el promedio de los valores de los vecinos. KNN es simple e intuitivo, pero puede ser costoso computacionalmente cuando el conjunto de datos es muy grande, ya que requiere calcular distancias entre observaciones.

3.2.6. Redes neuronales artificiales

Las redes neuronales artificiales también pueden utilizarse dentro del aprendizaje supervisado. Están formadas por capas de neuronas artificiales que transforman los datos de entrada hasta producir una salida. Cada neurona calcula una combinación ponderada de sus entradas y aplica una función de activación.

La operación básica de una neurona puede representarse como:

$$z = w_1x_1 + w_2x_2 + \dots + w_mx_m + b \quad (3.15)$$

Luego se aplica una función de activación:

$$a = \phi(z) \quad (3.16)$$

Donde (ϕ) puede ser una función sigmoide, ReLU, tangente hiperbólica u otra función no lineal.

Durante el entrenamiento, la red ajusta sus pesos para minimizar una función de pérdida. En problemas de clasificación, una función común es la entropía cruzada:

$$L = - \sum_{k=1}^K y_k \log(\hat{y}_k) \quad (3.17)$$

En problemas de regresión, puede utilizarse el error cuadrático medio. Las redes neuronales son la base del *Deep Learning*, especialmente cuando se utilizan múltiples capas ocultas. Son útiles para resolver problemas complejos, como reconocimiento de imágenes, procesamiento de lenguaje natural, predicción de series temporales y análisis de señales.

3.3. Aprendizaje no supervisado y sus modelos

El aprendizaje no supervisado es un enfoque del *Machine Learning* en el cual los modelos trabajan con datos que no poseen etiquetas o respuestas previamente definidas. En este caso el algoritmo solo dispone de las características de entrada y debe encontrar por sí mismo estructuras, relaciones o patrones internos dentro del conjunto de datos.

3.3.1. Conglomerados o clustering

El *clustering*, también llamado análisis de conglomerados es una de las tareas más representativas del aprendizaje no supervisado. Su objetivo es agrupar observaciones similares dentro de un mismo grupo, de tal manera que los elementos de un grupo sean más parecidos entre sí que con respecto a los elementos de otros grupos.

Matemáticamente, se parte de un conjunto de datos:

$$X = x_1, x_2, x_3, \dots, x_n \quad (3.18)$$

donde cada (x_i) representa una observación con varias características. El objetivo del clustering es dividir este conjunto en (K) grupos o clústeres:

$$C = C_1, C_2, \dots, C_K \quad (3.19)$$

de forma que las observaciones dentro de cada grupo sean similares según una medida de distancia o similitud.

3.3.2. K-Means

K-Means es uno de los algoritmos de clustering más conocidos y utilizados. Su objetivo es dividir un conjunto de datos en (K) grupos, donde cada grupo está representado por un centroide. El centroide corresponde al punto promedio de las observaciones asignadas a ese grupo.

La función objetivo de K-Means consiste en minimizar la suma de las distancias cuadradas entre cada observación y el centroide de su grupo:

$$J = \sum_{i=1}^n \sum_{k=1}^K r_{ik} |x_i - \mu_k|^2 \quad (3.20)$$

Donde (x_i) representa una observación, (μ_k) representa el centroide del clúster (k), (r_{ik}) indica si la observación (i) pertenece al clúster (k), y (J) es la función de costo que se busca minimizar.

Sin embargo, presenta algunas limitaciones. Requiere definir previamente el número de clústeres (K), es sensible a la inicialización de los centroides y puede verse afectado por valores atípicos.

3.3.3. Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales, es una técnica de reducción de dimensionalidad utilizada en aprendizaje no supervisado. Su propósito es transformar un conjunto de variables originales en un nuevo conjunto de variables llamadas componentes principales.

Estas nuevas variables se construyen de tal manera que la primera componente principal conserva la mayor cantidad posible de variabilidad de los datos, la segunda componente conserva la mayor variabilidad restante y así sucesivamente. Además, las componentes principales son ortogonales entre sí, es decir, no están correlacionadas.

Matemáticamente, PCA parte de una matriz de datos (X), generalmente centrada respecto a su media. Luego se calcula la matriz de covarianza:

$$\Sigma = \frac{1}{n-1} X^T X \quad (3.21)$$

A partir de esta matriz se obtienen los valores propios y vectores propios. Los vectores propios indican las direcciones principales de los datos, mientras que los valores propios indican la cantidad de varianza explicada por cada dirección.

PCA es útil para visualizar datos de alta dimensión, reducir ruido, disminuir el costo computacional y preparar datos antes de aplicar otros modelos. Por ejemplo, un conjunto de

datos con muchas variables puede reducirse a dos o tres componentes principales para ser representado gráficamente.

Capítulo 4

Aplicación computacional de modelos supervisados

Este capítulo tiene como propósito aplicar de manera práctica algunos modelos de *Machine Learning* supervisado mediante ejemplos desarrollados en Python. La finalidad es complementar la explicación teórica presentada en el capítulo anterior, mostrando cómo los modelos pueden implementarse, entrenarse, evaluarse y visualizarse mediante código.

4.1. Predicción del valor medio de viviendas en California mediante regresión lineal

4.1.1. Objetivo de la aplicación

El objetivo principal de esta aplicación es implementar y evaluar un modelo de inteligencia artificial basado en aprendizaje supervisado, específicamente mediante un algoritmo de regresión lineal simple. Se busca determinar la capacidad predictiva del modelo para estimar el valor medio de una vivienda partir del nivel de ingresos medios de la zona geográfica.

4.1.2. Descripción de la base de datos

Para el desarrollo de este modelo se utilizó el conjunto de datos de acceso público *California Housing*, provisto por la librería ***scikit-learn***. Este dataset recopila información estadística de los distritos censales de California en 1990. Cada registro representa una zona geográfica particular y contiene variables socioeconómicas y geográficas como la antigüedad de las viviendas, población, ocupación promedio, latitud y longitud.

Para efectos de la presente regresión lineal simple, se seleccionaron las siguientes variables analíticas:

- Variable predictora (Entrada): MedInc (Income), que representa el ingreso medio de los hogares en la zona (expresado en decenas de miles de dólares).

- Variable objetivo (Salida): MedHouseVal, que representa el valor medio de la vivienda en el distrito (expresado en cientos de miles de dólares).

4.1.3. Implementación del código en Python

A continuación, se detalla el fragmento de código central utilizado para la instanciación, entrenamiento y extracción de parámetros del modelo predictivo, el código completo lo encontramos en el anexo.

CREAR EL MODELO DE REGRESIÓN LOGÍSTICA

```
modelo = LinearRegression()
```

ENTRENAR EL MODELO

```
modelo.fit(X_train, y_train)
```

REALIZAR PREDICCIONES

```
y_pred = modelo.predict(X_test)
```

EVALUAR EL MODELO

```
mse = mean_squared_error(y_test, y_pred)
```

```
r2 = r2_score(y_test, y_pred)
```

```
pendiente = modelo.coef__[0]
```

```
interseccion = modelo.intercept__
```

4.1.4. Análisis y resultados

4.1.4.1. Gráfica regresión lineal




Figura 4.1: Regresión lineal: Ingreso medio vs valor de la vivienda

La *Figura 4.1* ilustra la dispersión de los datos reales pertenecientes al conjunto de prueba frente a la recta de ajuste óptimo calculada por el algoritmo. La pendiente positiva de la recta matemática corrobora una relación directamente proporcional: a mayor ingreso medio en la zona, se suscita un incremento en el valor de los bienes raíces.

Figura 4.1: Regresión lineal: Ingreso medio vs Valor de la vivienda

4.1.4.2. Gráfico de diagnóstico de predicción

En la *Figura 4.2* se presenta el diagnóstico de dispersión de los valores reales frente a las predicciones generadas. Se observa que en el rango de precios bajos y medios (valores reales entre 0.5 y 3.0), la densidad de las predicciones se alinea favorablemente con la diagonal de predicción ideal, validando la estabilidad del modelo para este sector socioeconómico. No obstante, se evidencia una distorsión horizontal en el umbral superior de 5.0, producto del truncamiento (tope máximo) presente en la base de datos original.




Figura 4.2: Valores reales vs Valores predichos

4.1.4.3. Métricas de evaluación

Coefficiente de determinación (R^2): Que en nuestro caso dio cerca de 0.46. Esto le dice a la audiencia que el ingreso económico de una familia es capaz de explicar, por sí solo, el 46 % del precio de una casa. El otro 54 % depende de factores externos no incluidos en este modelo simple.

Root Mean Squared Error (RMSE):

$$\text{RMSE} = \sqrt{0,7091} \approx 0,8421$$

Ahora sí, traduzcamos ese 0.8421 a dinero real:

$$0,8421 \times 100,000 \text{ USD} = 84,210 \text{ USD}$$

En promedio, cuando tu modelo intenta adivinar el precio de una casa basándose únicamente en los ingresos de la zona, se equivoca por aproximadamente \$84,210 dólares.

4.1.5. Conclusión y reflexión

Los resultados obtenidos demuestran que, si bien el ingreso familiar representa un predictor estadísticamente significativo y de alto impacto, la naturaleza del mercado inmobiliario es multifactorial. Un error promedio de \$84,210 USD resulta esperable al aislar una única variable de entrada mediante una regresión lineal simple.

Para optimizar la precisión predictiva y reducir los márgenes de error residuales, el trabajo monográfico concluye que la ruta técnica idónea consiste en la transición hacia un modelo de **Regresión Lineal Múltiple**, permitiendo al algoritmo correlacionar simultáneamente el impacto de la ubicación geográfica (latitud y longitud), el tamaño de la infraestructura y la densidad poblacional del sector.

4.2. Clasificación de tumores benignos y malignos mediante regresión logística

4.2.1. Objetivo

El objetivo de esta sección es implementar y evaluar un modelo de **regresión logística**, enmarcado en el aprendizaje supervisado, para resolver un problema de clasificación binaria. El algoritmo busca determinar de forma automatizada si un tumor mamario posee características benignas o malignas a partir de un conjunto de atributos morfológicos celulares.

4.2.2. Descripción base de datos

Para este modelo se empleó el dataset Breast Cancer Wisconsin (Diagnostic), integrado en la biblioteca *scikit-learn*. Cada registro describe las propiedades de los núcleos celulares presentes en la muestra mediante variables numéricas continuas, tales como: el radio, la

textura, el perímetro, el área, la suavidad, la compacidad, la concavidad y la simetría. La variable objetivo es de naturaleza dicotómica (binaria), donde las clases se definen como:

Clase 0 (Benigno): Ausencia de malignidad en la muestra.

Clase 1 (Maligno): Presencia de tejido tumoral cancerígeno.

4.2.3. Implementación del Código en Python

Debido a que las variables morfológicas poseen diferentes escalas y unidades de medida, se estructuró un flujo de trabajo optimizado mediante un canal de procesamiento (Pipeline). Este asegura el escalado previo de los datos antes de la etapa de ajuste:

CREAR EL MODELO DE REGRESIÓN LOGÍSTICA

```
modelo = Pipeline([
    (.escalador", StandardScaler()),
    (regresion_logistica", LogisticRegression(max_iter=1000))
])
```

ENTRENAR EL MODELO

```
modelo.fit(X_train, y_train)
```

REALIZAR PREDICCIONES

```
y_pred = modelo.predict(X_test)
y_prob = modelo.predict_proba(X_test)[:, 1]
```

EVALUAR EL MODELO

```
accuracy = accuracy_score(y_test, y_pred)
precision = precision_score(y_test, y_pred)
recall = recall_score(y_test, y_pred)
f1 = f1_score(y_test, y_pred)
auc = roc_auc_score(y_test, y_prob)
(Codigo completo pag tal)
```

4.2.4. Análisis y resultados

4.2.4.1. Distribución de clases

La Figura 4.3 detalla la proporción de la variable objetivo dentro del dataset. Este análisis de frecuencia es mandatorio en tareas de clasificación para identificar la presencia de un desbalance de clases que pudiera sesgar los criterios de decisión del algoritmo hacia la clase mayoritaria.




Imagen 4.3: Distribución de clases en la base de datos Breast Cancer

4.2.4.2. Matriz correlación

La Figura 4.4 expone la matriz de correlación de Pearson calculada para las variables seleccionadas. El coeficiente oscila en el intervalo $[-1, 1]$, donde los valores próximos a los extremos denotan asociaciones lineales fuertes (positivas o negativas) y los valores cercanos a cero indican la ausencia de dependencia lineal. Esta herramienta visual permite identificar fenómenos de multicolinealidad entre características (como el radio y el perímetro) y su relevancia respecto a la variable predictiva.




Imagen 4.4: Matriz de correlación de variables seleccionadas

4.2.4.3. Matriz de confusión

Para examinar la distribución exacta de los aciertos y las desviaciones del clasificador en el conjunto de prueba, se construyó la matriz de confusión presentada en la Figura 4.5. Los valores alojados en la diagonal principal corresponden a las clasificaciones correctas (Verdaderos Positivos y Verdaderos Negativos), mientras que las celdas periféricas delimitan los errores del modelo (Falsos Positivos y Falsos Negativos).




Imagen 4.5: Matriz de confusion – Regresion logistica

4.2.4.4. Métricas de evaluación

Métrica de Evaluación	Valor Obtenido	Porcentaje Equivalente
Exactitud (<i>Accuracy</i>)	0.9825	98.25 %
Precisión (<i>Precision</i>)	0.9861	98.61 %
Sensibilidad (<i>Recall</i>)	0.9861	98.61 %
Puntuación F1 (<i>F1-Score</i>)	0.9861	98.61 %
Área Bajo la Curva (<i>ROC-AUC</i>)	0.9954	99.54 %

Tabla 4.1: Métricas de evaluación

Las métricas de evaluación permiten analizar qué tan bien está funcionando el modelo de regresión logística. En este caso, el modelo obtuvo un **accuracy de 0.9825**, lo que significa que clasificó correctamente aproximadamente el 98,25 % de los casos.

4.2.5. Conclusiones

La implementación de la regresión logística demostró una alta eficacia y robustez para la detección automatizada de anomalías mamarias. El uso complementario del escalado estandarizado (StandardScaler) mitigó la disparidad de magnitudes entre las variables continuas, permitiendo una convergencia óptima del algoritmo.

Se concluye que, para problemas de clasificación binaria donde las fronteras de decisión presentan una tendencia lineal bien definida por los descriptores geométricos, la regresión logística constituye una solución óptima, de bajo costo computacional y con un nivel de interpretabilidad clínica superior al de arquitecturas de caja negra más complejas.

Capítulo 5

Aplicación computacional de modelos no supervisados

En este apartado se implementarán modelos que trabajan con datos no etiquetados. El objetivo será mostrar cómo estos algoritmos descubren estructuras internas, grupos, patrones o comportamientos atípicos en los datos.

5.1. Agrupamiento de flores Iris mediante K-Means

5.1.1. Objetivo

El objetivo de esta aplicación es implementar el algoritmo K-Means sobre la base de datos Iris, con el fin de identificar agrupamientos de flores a partir de dos características numéricas: longitud del pétalo y ancho del pétalo. Esta aplicación permite mostrar cómo un modelo de aprendizaje no supervisado puede encontrar patrones internos en los datos sin utilizar una variable objetivo durante el entrenamiento.

5.1.2. Descripción de la base de datos

Para este modelo se utilizó la clásica base de datos ***Iris*** (o *Iris flower dataset*), scikit-learn. El conjunto de datos consta de 150 observaciones morfológicas pertenecientes a tres especies distintas de flores: *Iris setosa*, *Iris versicolor* e *Iris virginica* (50 muestras por especie). Cada registro cuenta originalmente con cuatro variables numéricas continuas: longitud del sépalo, ancho del sépalo, longitud del pétalo y ancho del pétalo.

5.1.3. Implementación del Código en Python

A continuación, se presenta el fragmento de código diseñado para la configuración del algoritmo, el establecimiento del estado de aleatoriedad y la asignación categórica de los grupos:

```
# Instanciación del algoritmo K-Means con parametrización de clústeres
kmeans = KMeans(
n_clusters=3,
random_state=42,
n_init=10
)
# Ajuste del modelo y asignación simultánea de etiquetas de clúster
clusters = kmeans.fit_predict(X_escalado)
```

5.1.4. Análisis y resultados

5.1.4.1. Distribución real

La *Figura 5.1* exhibe la dispersión geométrica original del dataset Iris con base en las dimensiones de sus pétalos. Aunque las etiquetas de las especies reales se emplean en esta gráfica con fines comparativos y de validación posterior, es imperativo señalar que dicha información fue completamente omitida durante el proceso de entrenamiento del modelo.




Imagen 5.1: Distribución real de especies según medidas del pétalo

5.1.4.2. Optimización mediante el método del codo

Para determinar técnicamente el número óptimo de agrupamientos (K), se aplicó la técnica heurística del método del codo, ilustrada en la *Figura 5.2*. Este procedimiento evalúa la inercia del modelo (suma de las distancias cuadradas intra-clúster) a lo largo de un rango de valores de (K).





Imagen 5.2: Método del codo para seleccionar el número de clústeres

5.1.4.3. Clústeres encontrados por k-means

La Figura 5.3 expone el resultado de la segmentación ejecutada por el algoritmo de aprendizaje no supervisado. Al contrastar de manera visual esta proyección con la distribución real (Figura 5.1), se constata que K-Means logró reconstruir las fronteras naturales de los grupos de forma autónoma. El modelo separó perfectamente a la especie *Iris setosa* (debido a su claro aislamiento espacial) y delimitó con un margen mínimo de solapamiento la transición entre las especies *versicolor* y *virginica*.



Gráfica 5.2: Clústeres encontrados por K-Means

5.1.4.4. Métricas generales

Para cuantificar la cohesión y separación de los agrupamientos obtenidos, se calcularon los indicadores matemáticos de rendimiento que se detallan en la Tabla 5.1:

Parámetro / Métrica	Valor Obtenido
Número de Clústeres (\$K\$)	3
Inercia Final	18.0270
Coefficiente de Silueta (<i>Silhouette Score</i>)	0.6741

Tabla 5.1: Métricas generales

El análisis inferencial de las métricas establece lo siguiente:

- **Inercia Final:** El valor de *18.0270* denota un nivel óptimo de proximidad geométrica, lo que indica que las observaciones asignadas a cada clúster se encuentran concentradas a una distancia matemática reducida respecto a sus respectivos centroides.
- **Coefficiente de Silueta (*Silhouette Score*):** El modelo alcanzó una puntuación de *0.6741* (en una escala que oscila entre -1 y 1). Este resultado confirma la solidez de la segmentación, reflejando que los puntos no solo poseen una alta similitud con los miembros de su propio grupo (alta cohesión), sino que también se encuentran significativamente distanciados de los clústeres vecinos (alta separación).

5.1.5. Conclusión

La aplicación del algoritmo K-Means sobre el dataset Iris demostró la alta eficacia del aprendizaje no supervisado para la extracción automatizada de estructuras ocultas. Sin la intervención de etiquetas previas, el algoritmo identificó con precisión las tres firmas morfológicas del conjunto de datos guiándose únicamente por la proximidad euclidiana de las dimensiones del pétalo.

Se concluye que K-Means constituye una herramienta exploratoria de gran valor científico para la caracterización taxonómica y biológica, permitiendo establecer taxonomías y clasificaciones preliminares robustas sobre datos que carecen de categorización previa.

5.2. Análisis de Componentes Principales (PCA)

5.2.1. Objetivo de la aplicación

Implementar el **Análisis de Componentes Principales (PCA)** sobre el dataset *Wine* para reducir sus 13 dimensiones originales a un plano bidimensional, facilitando la visualización y eliminando la redundancia mediante variables ortogonales incorrelacionadas llamadas componentes principales (PC).

5.2.2. Descripción de la base de datos

Se utiliza el dataset ***Wine Recognition*** (scikit-learn), que contiene 178 muestras y 13 variables numéricas continuas de análisis químicos de tres tipos de vino (cultivares). La etiqueta de clase se excluyó del entrenamiento y se reservó únicamente para la validación visual posterior

5.2.3. Código Python

Tras estandarizar los ($\mu = 0$, $\sigma = 1$), se ejecuta el siguiente flujo:

```
# =====
# 7. APLICAR PCA CON TODAS LAS COMPONENTES
# =====
# Primero se aplica PCA con todas las componentes posibles.
# Esto permite analizar cuánta varianza explica cada componente.
pca_completo = PCA()
X_pca_completo = pca_completo.fit_transform(X_escalado)
```

```

varianza_explicada = pca_completo.explained_variance_ratio_
varianza_acumulada = np.cumsum(varianza_explicada)
# =====
# 10. APLICAR PCA CON 2 COMPONENTES
# =====
# Se reducen las 13 variables originales a 2 componentes principales.
pca_2 = PCA(n_components=2)
X_pca_2 = pca_2.fit_transform(X_escalado)

```

5.2.4. Análisis de resultados

5.2.4.1. Distribución de clases

La Figura 5.4 muestra la frecuencia de las tres clases de vino en el dataset, confirmando un balance adecuado para el análisis.






Imagen 5.4: distribución de clases de la base de datos Wine

5.2.4.2. Varianza explicada y acumulada

La primera componente (PC_1) concentra la mayor variabilidad (Figura 5.5). Al reducir el modelo a solo dos componentes (PC_1 y PC_2), la curva de varianza acumulada (Figura 5.6) demuestra que se logra retener **más del 55% de la información original**, proporción estadísticamente sólida para el análisis visual.



Grafica 5.5: Varianza explicada



Grafica 5.6: Varianza acumulada por componentes principales

5.2.4.3. Proyección de los datos con PCA

La Figura 5.7 corresponde a la proyección de los datos en el espacio formado por las dos primeras componentes principales. En esta visualización, cada punto representa una muestra de vino. Las clases reales se usan únicamente como referencia visual para interpretar si las componentes permiten separar grupos dentro de los datos.




Imagen 5.7: Proyeccion de la base de datos Wine usando PCA

5.2.4.4. Contribución de variables

Las Figuras 5.8 y 5.9 detallan el peso de las variables originales en cada componente. Características asociadas a los polifenoles (como flavonoides) dominan la estructura de la (PC_1), mientras que variables cromáticas (como intensidad de color) definen principalmente a la (PC_2).

En la componente principal 1




Imagen 5.8: Cargas de las varibales originales en PC1

En la componente principal 2




Imagen 5.9: Cargas de las variables originales en PC2

5.2.5. Conclusión

La aplicación del Análisis de Componentes Principales sobre la base de datos Wine permitió reducir un conjunto de múltiples variables químicas a dos componentes principales, facilitando la visualización e interpretación de la estructura interna de los datos. A través de la varianza explicada, se evidenció qué cantidad de información logra conservar cada componente y cómo las primeras componentes concentran una parte importante de la variabilidad del conjunto original.

En conclusión, PCA es una herramienta útil cuando se trabaja con bases de datos que contienen muchas variables, ya que permite simplificar la información, reducir redundancia, mejorar la visualización y apoyar el análisis previo a otros modelos de Machine Learning. Sin embargo, debe considerarse que al reducir la dimensionalidad también puede perderse parte de la información original, por lo que es importante analizar la varianza explicada antes de decidir cuántas componentes utilizar.

Capítulo 6

Análisis crítico, retos y tendencias futuras

El uso de técnicas de aprendizaje automático ha adquirido gran importancia en diferentes áreas debido a su capacidad para analizar datos, identificar patrones, realizar predicciones y apoyar la toma de decisiones. Sin embargo, el desarrollo de modelos de Machine Learning no depende únicamente de la selección del algoritmo, sino también de factores como la calidad de los datos, la seguridad de la información, el sesgo algorítmico, la interpretabilidad de los resultados y los recursos computacionales disponibles.

6.1. Calidad de los datos

La calidad de los datos es uno de los factores más importantes en cualquier proyecto de aprendizaje automático. Aunque un modelo puede estar construido con un algoritmo avanzado, sus resultados dependen directamente de la información utilizada durante el entrenamiento. Por esta razón, si los datos son incompletos, erróneos, duplicados, inconsistentes, ruidosos o poco representativos, las predicciones y conclusiones obtenidas pueden ser poco confiables.

En este sentido, la calidad de los datos no debe considerarse una etapa secundaria, sino una condición esencial para construir modelos confiables. Un buen análisis de datos comienza antes del entrenamiento del modelo y requiere comprender el origen, la estructura, el significado y las limitaciones de la información disponible. Por ello, etapas como la exploración, limpieza, transformación y preparación de los datos son fundamentales para mejorar el desempeño de los modelos y garantizar una interpretación adecuada de los resultados (García, Luengo y Herrera, 2015; Han, Kamber y Pei, 2012).

6.2. Privacidad y seguridad de la información

La privacidad y la seguridad de la información representan retos fundamentales en el uso de datos para Machine Learning. Muchos conjuntos de datos pueden contener información sensible relacionada con personas, instituciones, empresas, transacciones, historiales médicos, ubicación geográfica o comportamiento digital.

Cuando se utilizan datos reales, es necesario garantizar que la información sea tratada de forma ética y segura. Esto implica proteger la identidad de las personas, evitar el uso indebido de datos personales, aplicar mecanismos de anonimización cuando sea necesario y cumplir con las normas legales relacionadas con la protección de datos.

En el contexto de esta monografía, las bases de datos utilizadas provienen de bibliotecas académicas como scikit-learn, lo cual permite trabajar con información preparada para fines educativos. Sin embargo, en aplicaciones reales, el manejo de datos debe realizarse con mayores controles de seguridad, especialmente cuando se trabaja con información privada o sensible.

6.3. Costos computacionales

En modelos sencillos, como la regresión lineal o la regresión logística, el costo computacional suele ser bajo, especialmente cuando se trabaja con bases de datos pequeñas o medianas. Sin embargo, en modelos más complejos o con grandes volúmenes de datos, el entrenamiento puede requerir mayor capacidad de procesamiento.

Los modelos no supervisados también pueden presentar costos computacionales importantes. K-Means, por ejemplo, requiere calcular distancias entre observaciones y centroides, lo cual puede volverse costoso cuando el número de datos o variables es muy grande. PCA, por su parte, requiere operaciones matriciales que pueden ser exigentes en conjuntos de alta dimensionalidad.

El costo computacional también debe analizarse en relación con el beneficio esperado. No siempre es necesario usar el modelo más complejo. En muchos casos, un modelo simple, bien interpretado y entrenado con datos de calidad puede ser suficiente para resolver el problema. Por ello, la selección del modelo debe equilibrar precisión, interpretabilidad, recursos disponibles y propósito del análisis.

Capítulo 7

Conclusiones y recomendaciones

7.1. Conclusiones generales

El desarrollo de esta monografía permitió analizar la importancia de los datos en los procesos de Machine Learning, así como el papel que cumplen las técnicas supervisadas y no supervisadas en el análisis de información. A lo largo del trabajo se evidenció que los datos constituyen la base fundamental de cualquier modelo, ya que de su calidad, preparación y representatividad depende en gran medida la confiabilidad de los resultados.

En conclusión, el aprendizaje automático es una herramienta poderosa para analizar datos y apoyar la toma de decisiones. Sin embargo, su uso adecuado requiere comprender tanto los modelos como los datos, sus limitaciones, sus riesgos y el contexto en el que serán aplicados.

7.2. Recomendaciones para el uso adecuado del aprendizaje automático

Para utilizar adecuadamente técnicas de Machine Learning, se recomienda iniciar todo proyecto con una comprensión clara del problema que se desea resolver. Antes de seleccionar un modelo, es necesario definir el objetivo del análisis, identificar las variables disponibles y determinar si el problema corresponde a regresión, clasificación, agrupamiento o reducción de dimensionalidad.

También se recomienda realizar una exploración inicial de los datos antes del entrenamiento. Esta etapa permite identificar valores faltantes, datos duplicados, valores atípicos, errores de codificación o variables con escalas diferentes. Una correcta preparación de los datos puede mejorar significativamente el desempeño del modelo.

Se recomienda no depender únicamente de una métrica de evaluación. En clasificación, por ejemplo, deben analizarse medidas como accuracy, precision, recall, F1-score, matriz de confusión y ROC-AUC. En regresión deben revisarse métricas como MAE, MSE, RMSE y (R^2). En modelos no supervisados pueden emplearse indicadores como inercia, puntaje de silueta y varianza explicada.

Finalmente, se recomienda interpretar los resultados con sentido crítico. Un modelo puede producir resultados numéricamente buenos, pero aun así presentar sesgos, baja interpretabilidad o limitaciones frente a datos nuevos. Por esta razón, el aprendizaje automático debe entenderse como una herramienta de apoyo a la toma de decisiones, no como un reemplazo absoluto del análisis humano.

Bibliografía

- Ackoff, R. L. (1989). From data to wisdom. *Journal of Applied Systems Analysis*, 16, 3–9.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*.
- Davenport, T. H., & Prusak, L. (1998). *Working Knowledge: How Organizations Manage What They Know*. Harvard Business School Press.
- García, S., Luengo, J., & Herrera, F. (2015). *Data Preprocessing in Data Mining*. Springer.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly Media.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Han, J., Kamber, M., & Pei, J. (2012). *Data Mining: Concepts and Techniques* (3rd ed.). Morgan Kaufmann.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer.
- Kuhn, M., & Johnson, K. (2013). *Applied Predictive Modeling*. Springer.
- Mitchell, T. M. (1997). *Machine Learning*. McGraw-Hill.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., VanderPlas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Provost, F., & Fawcett, T. (2013). *Data Science for Business: What You Need to Know About Data Mining and Data-Analytic Thinking*. O'Reilly Media.
- Samuel, A. L. (1959). Some studies in machine learning using the game of checkers. *IBM Journal of Research and Development*, 3(3), 210–229.
- OpenAI. (2026). *ChatGPT* [Herramienta de inteligencia artificial generativa]. <https://chatgpt.com/>
- Alpaydin, E. (2020). *Introduction to machine learning* (4.^a ed.). MIT Press.

ÁPENDICE A

Códigos completos en Python

<https://github.com/Jholman22/Monografia-An-lisis-de-datos-mediante>